

多智能体网约车调度与路径规划

11 篇论文学习整合报告

内容包括：论文做了什么、方法与算法、关键指标、创新点、不足、以及你在对话中形成的判断和可融入论文的方向。

当前论文主线

已知地图 + 未知动态需求/乘客流/交通状态 + 多智能体车辆协同调度 + LLM 作为高层语义/目标/约束生成模块 + 传统规划/优化/RL 模块执行。

生成位置：/Users/didi/Documents/personalcodexfile/第二次课/output/pdf/多智能体网约车论文整合报告.pdf

生成日期：2026-10-01

一、整体结论

这 11 篇论文可以分成五类：LLM 调度技能生成、LLM 路径规划与评测、语言/视觉地图、传统与数学优化派单、多智能体强化学习派单。真正适合你作为论文主线的，不是让 LLM 直接派车或直接算路径，而是把 LLM 放在高层：理解自然语言目标，生成可执行约束，解释和审计调度目标；底层再交给多智能体调度、数学优化器和路径规划模块。

模块	可以吸收的论文	放在你论文里的作用
LLM 语义/提示词层	RideSkill, LLM+P	把自然语言业务目标转成目标函数、约束、评分规则或 agent 友好任务说明。
地图/路径语义层	LM-Nav, VLMaps, AIFP, GridRoute	说明 LLM 可理解路径语义，但底层路径必须被验证；地图可做成 agent 可读结构。
多智能体派单层	DualG-MARL, Order-Vehicle Distribution Matching	把每辆车/每个区域建模为协同 agent，派单要考虑未来车辆分布和供需平衡。
数学优化器/合规底座	Alonso-Mora, T-Share	负责可解释、可约束、可审计的 trip-vehicle assignment、路线插入、等待/绕路/容量约束。
次要参考层	GNN Fleet Management	可作为历史需求热区和空车重定位模块，但不适合作为核心创新。

二、当前建议的论文创新表达

可以把你的论文定位为：面向动态订单和未知需求变化的 LLM 约束生成驱动多智能体滚动调度方法。LLM 不直接做派单，而是像 agent 友好版 PRD 一样，把业务目标转成可审计的调度约束；多智能体模块负责车辆协同；数学优化器负责保证容量、等待、绕路、承诺订单等硬约束。

- 不要把创新写成“我重新发明一个复杂派单算法”。这会很难，也不必要。
- 更稳的写法是“我组合已有合规优化器 + 多智能体状态理解 + LLM 目标/约束生成”。
- 核心差异点放在乘客公平、区域等待时间、自然语言目标鲁棒性、未知人流/突发事件、以及调度解释上。
- 论文验收时可以清楚区分：调度决定哪辆车接谁，路径规划决定怎么走，实时重规划负责新订单出现后的比较和调整。

三、逐篇论文整理

1. RideSkill: A Hierarchical Algorithm for Generalized Ride Sharing with LLM-Driven Automatic Evolution

定位：LLM 参与网约车调度技能生成，是你最直接的起点论文。

维度	内容
这篇讲了什么	论文做的是多智能体 ride-sharing 调度和车辆重定位。它把复杂调度拆成可复用技能，由 LLM 离线生成和演化代码，线上执行阶段不再每一步调用 LLM。
你的看法/可融入点	你认可它的不足，并且可把这些不足直接变成自己的改进点：乘客公平、自然语言目标鲁棒性、代码安全审计、弱模型可用性。

方法和算法

- 层级结构：skill generator 生成候选技能，combiner 组合技能，repositioner 做车辆重定位。
- LLM 主要用于离线生成目标函数、规则或代码片段，再通过仿真反馈筛选。
- 调度目标包括服务率、完成率、等待时间、绕路、车辆利用率等。

关键指标

- Hour 场景：Reward 7654±1497，Service 0.92±0.06，Complete 0.83±0.05，Wait 1.12±0.15，Ride 5.24±0.24，Detour 0.16±0.02，Util 0.90±0.10。
- Fleet 场景：Reward 7907±2945，Service 0.66±0.24，Complete 0.61±0.21，Wait 1.22±0.10，Ride 4.24±0.80，Detour 0.19±0.02，Util 0.95±0.02。
- Speed 场景：Reward 9457±1371，Service 0.79±0.13，Complete 0.72±0.13，Wait 1.32±0.38，Ride 4.96±1.07，Detour 0.20±0.05，Util 0.95±0.00。
- Cap≤4 场景：Reward 6538±2667，Service 0.56±0.22，Complete 0.51±0.20，Wait 1.22±0.11，Ride 5.17±0.27，Detour 0.17±0.02，Util 0.93±0.02。
- Cap>4 场景：Reward 9709±301，Service 0.82±0.00，Complete 0.74±0.00，Wait 1.23±0.00，Ride 4.74±0.00，Detour 0.22±0.00，Util 0.95±0.00。

创新点

- 把 LLM 从实时决策器变成离线技能演化器，降低线上不稳定风险。
- 把调度技能、组合器、重定位器分层，适合复杂 ride-sharing 场景泛化。
- 证明 LLM 可参与生成优化策略，而不只是解释结果。

不足

- 公平性主要看车辆工作量是否均衡，没有深入看乘客公平。
- 自然语言目标测试较少，没有覆盖模糊、矛盾、恶意、业务不完整目标。
- 依赖 LLM 生成代码，即使有 sandbox 和审计，长期维护、安全风险、代码偏差仍存在。
- 开源 LLM 结果明显弱于 Claude，方法上限受底层 LLM 能力影响大。

来源：https://papers.nips.cc/paper_files/paper/2025/file/dc8f650f21f1a0c5dc4f7f8ade889de8-Paper-Conference.pdf

2. AIFP: Adaptive Iterative Feedback Prompting for Obstacle-Aware Path Planning via LLMs

定位：LLM 路径规划反馈循环，可作为“LLM 规划不可靠，需要外部校验”的论据。

维度	内容
这篇讲了什么	论文让 LLM 生成候选路径点，再用几何工具检查是否碰撞。如果路径无效，就把失败原因反馈给 LLM，让它迭代重规划。
你的看法/可融入点	适合作为辅助论文：说明 LLM 可以参与路径规划，但不能把 LLM 当成可靠底层规划器。你的系统更适合让 LLM 提目标或约束，再由规划器校验。

方法和算法

- LLM 提出 waypoint。
- Shapely 或几何检测器检查障碍物碰撞。
- 不合法则反馈具体错误，要求 LLM 修改路径。
- 适用于连续二维空间的障碍规避，但主要是单智能体。

关键指标

- 单障碍：AIFP 成功率 55.6%，naive 22.3%，平均迭代 N 20.6，路径长度 PL 17.6。
- 双障碍：成功率 36.7%，naive 14.0%，N 24.8，PL 37.7。
- 随机障碍：成功率 31.5%，naive 12.5%，N 27.7，PL 29.1。
- 移动障碍：成功率 48.5%，N 22.8，PL 24.1。
- 移动目标：成功率 51.5%，N 14.9，PL 15.4。

创新点

- 把 LLM 输出和外部几何验证结合，形成可反馈的规划闭环。
- 证明单纯 prompt 不够，必须有碰撞检测和失败反馈。
- 为“LLM 高层生成，传统模块验证执行”的架构提供证据。

不足

- 成功率仍然偏低，随机障碍只有 31.5%。
- 迭代次数多，成本和延迟高。
- 主要是单智能体，没有处理多车协同。
- 连续二维几何环境较简单，不是真实道路网络。

来源：<https://arxiv.org/abs/2409.12871>

3. GridRoute: A Benchmark for LLM-Based Route Planning with Cardinal Movement in Grid Environments

定位：LLM 路径规划评测基准，用来说明 LLM 在严格路径输出上很脆弱。

维度	内容
这篇讲了什么	论文构造网格迷宫，让 LLM 输出上下左右路径，并用 Dijkstra 标准答案评估可达性和最优性。
你的看法/可融入点	适合作为评测/反例：如果 LLM 连网格路径都容易输出失败，就更不能让它直接承担实时网约车底层派单或路径规划。

方法和算法

- 把地图离散成 10x10、20x20、30x30 网格。
- 只允许上、下、左、右移动。
- Dijkstra 生成标准最短路径。

- 评估 LLM 输出是否连通、可行、最优。

关键指标

- 课程本地小样本复现中，Dijkstra 参考自检前 10 个样本：CR=100%，FR=100%，OR=100%，GM=1.0，MSE=0.0。
- OpenRouter openai/gpt-oss-20b + algorithm prompt，前 10 个样本：CR=30%，FR=30%，有效子集 OR=100%，GM=1.0，MSE=0.0，约 7 个输出为空或无法解析。
- 注意：Dijkstra 100% 是评测器/参考答案自检，不是 LLM 成绩。

创新点

- 提供标准化的 LLM 路径规划考试。
- 把可达、可行、最优、长度误差等指标拆开。
- 有利于证明 LLM 输出格式和路径合法性都需要校验。

不足

- 静态网格环境，离真实路网较远。
- 单智能体，没有多车辆协同。
- 强依赖 prompt 和输出格式。
- 不能直接代表真实网约车调度能力。

来源：<https://arxiv.org/abs/2406.00566>

4. LM-Nav: Robotic Navigation with Large Pre-Trained Models of Language, Vision, and Action

定位：让 agent 按人的地标逻辑理解路线，可并入路径规划语义层。

维度	内容
这篇讲了什么	论文让机器人根据自然语言导航。LLM 从指令中抽取地标序列，CLIP 等视觉语言模型识别地标，低层导航模型执行运动。
你的看法/可融入点	你认为这篇很好，可以加入自己的想法，作为路径规划的一部分：它让 agent 用类似人的地标逻辑理解路线。

方法和算法

- LLM 把自然语言拆成地标序列。
- 视觉语言模型把地标和图像节点匹配。
- ViNG/VNM 在拓扑图上执行导航。
- LLM 不直接控制机器人动作，而是做语义解析。

关键指标

- 20 个真实户外导航指令，总路线超过 6 km，目标距离最高约 800 m。
- GPS-Nav no VNM, EnvSmall-10：Net Success 0.23，Efficiency 0.93，#Diseng 0.75，Planning Success 0.90。
- LM-Nav EnvSmall-10：Net Success 0.80，Efficiency 0.96，#Diseng 0.10，Planning Success 0.90。
- LM-Nav EnvLarge-10：Net Success 0.80，Efficiency 0.89，#Diseng 0.00，Planning Success 0.80。
- LLM 地标抽取：GPT-3 1.00，GPT-J-6B 0.80，GPT-NeoX-20B 0.72。VLM 地标识别：CLIP-ViT 0.87，ViLD 0.38，Faster-RCNN 0.07。

创新点

- 把语言、视觉、动作模型组合成导航系统。
- 证明 LLM 适合做高层语义分解，而不是直接做低层控制。
- 用地标逻辑连接人类指令和机器人地图。

不足

- 需要预先探索过的环境或拓扑图。
- 主要是单机器人导航，不是多车调度。
- 依赖可识别地标，对复杂业务约束支持有限。

来源：<https://proceedings.mlr.press/v205/shah23b.html>

5. VLMaps: Visual Language Maps for Robot Navigation

定位：把地图变成 agent 可理解、可语言查询的形式。

维度	内容
这篇讲了什么	论文把 RGB-D、SLAM 和视觉语言特征结合，构建可被语言查询的语义地图。机器人可以根据“去椅子旁边”“到桌子左边”这类描述定位目标。
你的看法/可融入点	你总结得很准确：LM-Nav 更像让 agent 按人的地标逻辑理解路线，VLMaps 更像把地图变成 agent 可理解的形式。对网约车来说，地图大体已知，真正需要改进的是未知人流、动态需求和多智能体协同。

方法和算法

- 用 SLAM/3D 信息建立空间地图。
- 用 LSeg/CLIP 等模型提取像素或区域的语言特征。
- 把语言特征投影到 top-down map。
- LLM 或语言模块把任务转换为空间目标，再在地图上规划。

关键指标

- 多目标导航 VLMaps：1/2/3/4 个连续目标成功数为 59/34/22/15，独立成功 59。
- 对比：LM-Nav 为 26/4/1/1，CoW 为 42/15/7/3，CLIP Map 为 33/8/2/0，GT Map 为 91/78/71/67。
- 空间语言导航 VLMaps：62/33/14/10；LM-Nav：5/5/0/0；CoW：33/5/0/0；CLIP Map：19/0/0/0；GT Map：76/48/33/29。
- 跨平台实验：LoCoBot+ground map SR 53%, SPL 49.0；Drone+ground map SR 53%, SPL 41.8；Drone+drone map SR 56%, SPL 45.4。
- 真实机器人 HSR：374 帧建图，20 个空间目标，成功 10/20。

创新点

- 把地图从几何坐标升级为语言可查询的语义地图。
- 支持开放词汇目标，不只限于固定类别。
- 为 LLM 和规划器之间提供了地图接口。

不足

- 主要面向室内/机器人导航，不是网约车路网。
- 需要传感器建图，网约车场景里道路地图通常已知。
- 未知的是乘客流动和交通状态，不是地图本身。
- 不是多智能体调度方法。

来源：<https://vlmaps.github.io/>

6. A Multi-Agent Reinforcement Learning Scheduling Algorithm Integrating State Graph and Task Graph Structural Modeling for Ride-Sharing Dispatching (DualG-MARL)

定位：多智能体网约车调度主线论文，与你的想法相似。

维度	内容
这篇讲了什么	论文把车辆状态和乘客任务分别建图，用图神经网络和多智能体强化学习做 ride-sharing 派单。
你的看法/可融入点	你认可这篇和你的想法很像，也提到 CNN/GNN 状态理解模块可以考虑。它适合放在你论文主线的“多智能体协同调度层”。

方法和算法

- 车辆状态图：表示车辆位置、容量、可用性和附近车辆关系。
- 任务图：表示乘客请求、起终点、任务冲突或组合关系。
- GNN 学习两个图中的结构信息，MARL 负责多车协同决策。
- 目标包括等待时间、接单率、车辆利用率、绕路比例。

关键指标

- 相对 CoopRide，在 Manhattan：AWT -0.27 分钟，ORR +2.3%，VUR +3.5%，ADR -0.05。
- 相对 CoopRide，在 Queens：AWT -0.35 分钟，ORR +2.7%，VUR +3.9%，ADR -0.06。

创新点

- 同时建模车辆状态图和任务图，而不是只看单一状态表。
- 把 GNN 结构表达与多智能体强化学习结合。
- 比单纯网格或历史热区方法更接近多车协同派单。

不足

- 主要依赖历史/仿真数据，没有真实线上 A/B。
- 没有自然语言目标输入。
- 没有直接建模未知行人流动，更多是从历史订单分布学习。
- 公平性分析有限。
- 重点是派单，不是完整路径规划。

来源：<https://www.nature.com/articles/s41598-026-35004-8>

7. Optimizing Large-Scale Fleet Management on a Road Network using Multi-Agent Deep Reinforcement Learning with Graph Neural Network

定位：真实路网上的车队重定位，可作为小层参考，但不是你的主创新。

维度	内容
这篇讲了什么	论文研究大量车辆如何在真实道路网络上重定位，让空闲车辆提前移动到未来可能有订单的区域。
你的看法/可融入点	你的认可度比较低，认为它只能作为“历史需求热区/车辆重定位”的小模块参考，不适合作为论文核心。

方法和算法

- 把道路网络建成图，路口或路段作为节点/边。

- 用 GNN 传播路网邻接信息。
- 用多智能体深度强化学习决定空车向哪些相邻道路移动。
- 用随机策略避免所有车辆集中到同一个高 Q 值区域。

关键指标

- Order Response Rate 在 100% 司机数量下 Pow 方法约 0.800。
- 50% 司机数量下约 0.601，20% 司机数量下约 0.310。
- 同星期不同日期测试约 0.782，不同星期测试约 0.771。
- 对比 Random 约 0.669/0.462/0.225，Proportional 约 0.694/0.490/0.238， ϵ -Greedy 约 0.752/0.541/0.280，Entropy 约 0.783/0.588/0.304。

创新点

- 真实路网图比规则网格更贴近网约车场景。
- GNN 表达道路连接关系，MARL 做车队重定位。
- 指出纯贪心会导致车辆扎堆，需要概率分散。

不足

- 本质上还是基于历史需求学习哪里可能有单。
- 只是路径规划/调度中的很小一层，偏空车重定位。
- 没有自然语言目标、乘客公平、完整派单和路径规划闭环。
- 对突发未知人流的处理能力有限。

来源：<https://arxiv.org/abs/2011.06175>

8. LLM+P: Empowering Large Language Models with Optimal Planning Proficiency

定位：LLM 作为自然语言到形式化约束的翻译层，和 agent 友好版 PRD 思路相似。

维度	内容
这篇讲了什么	论文不让 LLM 直接求解规划，而是让 LLM 把自然语言任务转换为 PDDL，再交给传统规划器生成最优或可行计划。
你的看法/可融入点	你认为这和工作中 agent 友好版 PRD 的尝试很像，可以作为提示词层/语义转约束层的创新来源。

方法和算法

- 用户给自然语言任务。
- LLM 生成 PDDL problem：初始状态、目标状态、对象、约束。
- Fast Downward 等 planner 求解。
- LLM 再把机器计划翻译回自然语言。

关键指标

- Barman：LLM+P 20% 最优，100% 可行。
- Blocksworld：LLM+P 90%。
- Floortile：LLM+P 0%。
- Grippers：LLM+P 95% 最优，100% 可行。
- Storage：LLM+P 85%。
- Termes：LLM+P 20%。
- Tyreworld：LLM+P 10% 最优，90% 可行。

- 直接让 LLM 自己规划通常更差，例如 Blocksworld 直接 LLM 约 15% 最优，LLM+P 到 90%；Grippers 直接 LLM 约 35%，LLM+P 到 95%。

创新点

- 明确了 LLM 的合理位置：语义接口和形式化问题生成器。
- 把可验证、可优化的求解交给传统规划器。
- 适合迁移到“业务目标 -> 调度约束 -> 数学优化器”的架构。

不足

- 依赖人工写好的 PDDL domain。
- 主要是静态任务，不是实时动态订单。
- 不是多智能体网约车。
- LLM 生成 PDDL 可能漏条件或写错状态。
- 复杂空间关系任务仍然弱，例如 Floortile 为 0%。

来源：<https://arxiv.org/abs/2304.11477>

9. Multi-Agent Reinforcement Learning for Order-dispatching via Order-Vehicle Distribution Matching

定位：派单核心论文：当前派单要影响未来车辆分布。

维度	内容
这篇讲了什么	论文把每辆空闲车看成 agent，让车辆在候选订单中选择，使接单后的车辆分布尽量匹配未来订单分布。
你的看法/可融入点	你认可这篇。它可放在“多智能体派单”部分，说明每辆车可以作为 agent，派单要考虑未来分布，而不是只看最近距离。

方法和算法

- Action Selection Q-learning：动作空间随订单变化，网络输入状态和订单，输出该订单的 Q 值。
- Order-Vehicle Distribution Matching：让未来车辆分布接近未来订单分布。
- KL Divergence：衡量两个分布差距，并作为优化信号。

关键指标

- 模拟环境相对 NOD：低订单分布变化 ADI +25.12%，ORR +13.40%。
- 中等变化：ADI +20.94%，ORR +7.89%。
- 高变化：ADI +13.47%，ORR +4.61%。
- 真实城市数据集：City A ADI +6.46%，ORR +3.07%；City B ADI +4.94%，ORR +3.30%；City C ADI +6.12%，ORR +3.01%。

创新点

- 把派单看成影响未来城市车辆分布的长期决策。
- 解决订单动作空间动态变化的问题。
- 比最近订单派单更关注长期收益和供需平衡。

不足

- 城市仍然网格化，真实道路细节弱。
- 主要优化 ADI 和 ORR，公平性不足。

- 依赖历史数据和模拟器，对突发人流不够强。
- 没有 LLM，不能处理自然语言业务目标。
- 路径和 ETA 更多依赖外部模块。

来源：<https://arxiv.org/abs/1910.02591>

10. On-demand High-capacity Ride-sharing via Dynamic Trip-Vehicle Assignment

定位：实时拼车数学优化器，可作为你的底层合规模块。

维度	内容
这篇讲了什么	论文解决多个乘客、多个车辆、容量限制、等待限制下的实时拼车匹配。系统要决定哪些乘客组成 trip，哪辆车服务，接送顺序如何安排。
你的看法/可融入点	你认为如果自己写算法会太难，但这个算法可以和其他层结合，合规的话完全可以作为数学优化器的一部分。这是非常适合你论文落地的底层模块。

方法和算法

- RV-graph：Request-Vehicle graph，用于判断订单和车辆、订单和订单之间是否可组合。
- RTV-graph：Request-Trip-Vehicle graph，把多个订单组合成 trip，再判断车辆是否能完成。
- ILP 整数线性规划：每辆车最多选一个 trip，每个订单要么服务要么放弃，目标最小化等待、绕路和未服务惩罚。
- 支持每 30 秒滚动批处理和上车前重新匹配。

关键指标

- 纽约曼哈顿出租车数据：约 300 万请求，13,586 辆活跃出租车，路网 4,092 个节点、9,453 条边。
- 每 30 秒批量处理一次，同时待处理订单池最多约 2,000 个。
- 3,000 辆车、容量 2：服务 94% 需求，平均等待 3.2 分钟，平均延误 1.5 分钟。
- 3,000 辆车、容量 4：服务 98% 需求，平均等待 2.7 分钟，平均延误 2.3 分钟。
- 2,000 辆车、容量 10：服务 98% 需求，平均等待 2.8 分钟，平均延误 3.5 分钟。
- 约 15% 的纽约活跃出租车规模可达到 98% 服务率，约 90% 行程可共享。

创新点

- 把派单、拼车组合、接送顺序和路径可行性放在一个优化框架里。
- 相比纯学习方法，可解释、可约束、可合规。
- 支持实时滚动重规划。

不足

- 没有 LLM，不能直接理解自然语言业务目标。
- 需求来自历史回放，不是真正预测未知人流。
- 公平性不足，没有深入区域或乘客群体公平。
- 中心化优化，不是多智能体协同学习。
- 乘客行为假设较理想。

来源：<https://www.pnas.org/doi/10.1073/pnas.1611675114>

11. T-Share: A Large-Scale Dynamic Taxi Ridesharing Service

定位：实时拼车工程化算法，可作为候选车辆筛选和路线插入层。

维度	内容
这篇讲了什么	论文构建大规模动态出租车拼车系统。新订单到来后，系统快速找可能接单的车，并尝试把新乘客的上下车点插入车辆当前路线。
你的看法/可融入点	这篇适合放在传统实时拼车优化部分。它不是你的全部创新，但很适合成为底层“能不能顺路带上你”的快速判断器。

方法和算法

- 时空索引：快速筛选可能接得上订单的车辆。
- 插入式路径规划：把 pickup 和 dropoff 插入现有路线，而不是全局从零重算。
- 约束检查：最大等待时间、最大绕路、车辆容量、路线可行性。
- 懒惰最短路：减少重复最短路计算，提升实时性。

关键指标

- 北京出租车数据：约 33,000 辆出租车，3 个月数据，超过 1000 万出行请求。
- 系统响应可做到毫秒级。
- 订单/出租车比例为 6 时，可多服务约 25% 的出租车用户。
- 总行驶距离减少约 13%。
- 估算每年节省约 1.2 亿升汽油。
- 合理分账设置下司机收益可提升约 19%。
- 懒惰最短路策略可使计算成本下降约 83%。

创新点

- 把实时拼车做成大规模可运行系统。
- 用候选车辆筛选、路线插入和约束检查降低计算复杂度。
- 适合作为轻量级可行性检查器，而不是每次都调用全局优化。

不足

- 主要是启发式规则和工程优化，不是智能体协同学习。
- 出租车拼车场景，不完全等于自动驾驶网约车。
- 没有 LLM，也没有自然语言业务目标。
- 公平性不足，未来未知人流建模弱。

来源：<https://www.microsoft.com/en-us/research/publication/t-share-a-large-scale-dynamic-taxi-ridesharing-service/>

四、可以直接写进论文的整合框架

层级	输入	核心方法	输出	对应论文
1. 业务目标理解层	自然语言目标、业务规则、验收口径	LLM+P 式语义转约束；RideSkill 式目标函数/技能生成	可审计的约束、目标权重、异常目标检查	LLM+P, RideSkill
2. 状态理解层	地图、路网、订单、车辆、交通、区域需求	GNN/CNN/统计预测，把状态变成调度可用特征	供需状态、区域风险、未来需求提示	DualG-MARL, Fleet GNN, VLMaps
3. 多智能体派单层	车辆 agent、订单、约束、状态特征	MARL 或分布匹配，考虑长期车辆分布	订单-车辆候选匹配和协同策略	OVDM, DualG-MARL
4. 数学优化器层	候选匹配、容量、等待、绕路、承诺订单	ILP、RTV/RV 图、插入式路径规划	合法可执行的派单和接送顺序	Alonso-Mora, T-Share
5. 验证与反馈层	路径、调度结果、失败原因	碰撞/约束检查、格式评测、仿真反馈	重规划反馈、鲁棒性评估	AIFP, GridRoute

建议保留的 10 篇

如果课程要求最终只保留 10 篇，建议把认可度较低的 Fleet GNN/MARL 车队重定位论文放到备选或简短相关工作中。主清单可保留：RideSkill、AIFP、GridRoute、LM-Nav、VLMaps、DualG-MARL、LLM+P、Order-Vehicle Distribution Matching、Alonso-Mora Dynamic Trip-Vehicle Assignment、T-Share。

可形成的论文观点

- 现有 LLM 方法证明了自然语言可参与规划，但 LLM 直接生成路径或代码仍存在稳定性、安全性和维护风险。
- 现有多智能体调度方法能提升接单率、等待时间和车辆利用率，但多数缺少自然语言目标和乘客公平建模。
- 现有数学优化方法可解释、可合规、可约束，但目标通常固定，难以直接响应复杂业务语言和突发场景。
- 因此，较稳的创新不是替代传统规划器，而是用 LLM 生成和审计高层目标，用多智能体方法处理协同，用数学优化器保证执行合法。

五、术语速查

术语	解释
调度/派单	决定哪辆车接哪个乘客或哪个 trip。
路径规划	决定车辆从当前位置到接乘点、再到目的地怎么走。
实时重规划	新订单、交通变化、突发需求出现后，重新比较并调整调度或路线。
MARL	Multi-Agent Reinforcement Learning，多智能体强化学习。多辆车或多个区域作为 agent 协同决策。
GNN	Graph Neural Network，图神经网络。适合表达道路网络、车辆关系、任务关系。
CNN	Convolutional Neural Network，卷积神经网络。适合处理网格化区域状态或热力图。
ILP	Integer Linear Programming，整数线性规划。变量通常是 0/1，用来表示是否选择某个匹配或路线。
RV-graph	Request-Vehicle graph，订单和车辆之间的可行性图。
RTV-graph	Request-Trip-Vehicle graph，订单组合、行程和车辆之间的可行性图。
PDDL	Planning Domain Definition Language，规划问题描述语言，用来描述状态、动作、前提和目标。

术语	解释
ORR	Order Response Rate，订单响应率。成功服务订单数除以总订单数。
ADI	Accumulated Driver Income，司机累计收入。
AWT	Average Waiting Time，平均等待时间。
ADR	Average Detour Ratio，平均绕路比例。
VUR	Vehicle Utilization Rate，车辆利用率。
SPL	Success weighted by Path Length，成功率按路径长度效率加权后的导航指标。

六、参考链接

1. RideSkill: A Hierarchical Algorithm for Generalized Ride Sharing with LLM-Driven Automatic Evolution
https://papers.nips.cc/paper_files/paper/2025/file/dc8f650f21f1a0c5dc4f7f8ade889de8-Paper-Conference.pdf
2. AIFP: Adaptive Iterative Feedback Prompting for Obstacle-Aware Path Planning via LLMs
<https://arxiv.org/abs/2409.12871>
3. GridRoute: A Benchmark for LLM-Based Route Planning with Cardinal Movement in Grid Environments
<https://arxiv.org/abs/2406.00566>
4. LM-Nav: Robotic Navigation with Large Pre-Trained Models of Language, Vision, and Action
<https://proceedings.mlr.press/v205/shah23b.html>
5. VLMaps: Visual Language Maps for Robot Navigation
<https://vlmaps.github.io/>
6. A Multi-Agent Reinforcement Learning Scheduling Algorithm Integrating State Graph and Task Graph Structural Modeling for Ride-Sharing Dispatching (DualG-MARL)
<https://www.nature.com/articles/s41598-026-35004-8>
7. Optimizing Large-Scale Fleet Management on a Road Network using Multi-Agent Deep Reinforcement Learning with Graph Neural Network
<https://arxiv.org/abs/2011.06175>
8. LLM+P: Empowering Large Language Models with Optimal Planning Proficiency
<https://arxiv.org/abs/2304.11477>
9. Multi-Agent Reinforcement Learning for Order-dispatching via Order-Vehicle Distribution Matching
<https://arxiv.org/abs/1910.02591>
10. On-demand High-capacity Ride-sharing via Dynamic Trip-Vehicle Assignment
<https://www.pnas.org/doi/10.1073/pnas.1611675114>
11. T-Share: A Large-Scale Dynamic Taxi Ridesharing Service
<https://www.microsoft.com/en-us/research/publication/t-share-a-large-scale-dynamic-taxi-ridesharing-service/>